Aprendizagem 2023/24

Homework II – Group 024

(ist105887, ist106228)

I. Pen-and-paper

1)

d(A,B) = d(A1, B1) + d(A2,B2)

y1 is categorical so:
d(A1,B1) = 0 if A1=B1, else 1

Split the data into one test variable and the rest as training variables.
Identify the knn with k=5 and then choose the mode class of the neighbors.

using x1 as test point:
d(x1, x2) = 2 ; d(x1, x3) = 1; d(x1, x4) = 0; d(x1, x5) = 1; d(x1, x6) = 1; d(x1, x7) = 1; d(x1, x8) = 2
{x3, x4} = P; {x5, x6, x7} = N
X1 is predicted as negative.

using x2 as test point:
d(x2, x1) = 2 ; d(x2, x3) = 1; d(x2, x4) = 1; d(x2, x5) = 1; d(x2, x6) = 1; d(x2, x7) = 1; d(x2, x8) = 0
{x3, x4} = P; {x5, x6, x8} = N
X2 is predicted as negative

using x3 as test point:
d(x3, x1) = 1 ; d(x3, x2) = 1; d(x3, x4) = 2; d(x3, x5) = 2; d(x3, x6) = 2; d(x3, x7) = 0; d(x3, x8) = 1
{x1,x2,x4} = P; {x7,x8} = N
X3 is predicted as positive

using x4 as test point:
d(x4, x1) = 0 ; d(x4, x2) = 2; d(x4, x3) = 1; d(x4, x5) = 1; d(x4, x6) = 1; d(x4, x7) = 1; d(x4, x8) = 2
{x1,x3} = P; {x5, x6, x7} = N
X4 is predicted as negative

using x5 as test point:
d(x5, x1) = 1 ; d(x5, x2) = 1; d(x5, x3) = 2; d(x5, x4) = 1; d(x5, x6) = 0; d(x5, x7) = 2; d(x5, x8) = 1
{x1,x2,x4} = P; {x6,x8} = N
X5 is predicted as positive

using x6 as test point:
d(x6, x1) = 1 ; d(x6, x2) = 1; d(x6, x3) = 2; d(x6, x4) = 1; d(x6, x5) = 0; d(x6, x7) = 2; d(x6, x8) = 1
{x1,x2,x4}= P; {x5, x8} = N
X6 is predicted as positive

using x7 as test point:
d(x7, x1) = 1 ; d(x7, x2) = 1; d(x7, x3) = 0; d(x7, x4) = 1; d(x7, x5) = 2; d(x7, x6) = 2; d(x7, x8) = 1
{x1,x2,x3,x4} = P; {x8} = N
X7 is predicted as positive

using x8 as test point:
d(x8, x1) = 2 ; d(x8, x2) = 0; d(x8, x3) = 1; d(x8, x4) = 2; d(x8, x5) = 1; d(x8, x6) = 1; d(x8, x7) = 1
{x2,x3} = P; {x5,x6,x7} = N
X8 is predicted as negative

Aprendizagem 2023/24

Homework II – Group 024

(ist105887, ist106228)

Predicted / Target	Positive	Negative
Positive	1	3
Negative	3	1

True Positive	True Negative	False Negative	False Positive
1	1	3	3

Precision = TP/(TP+FP) = 25%
Recall = TP/(TP+FN) = 25%
F1=2*Precision*Recall/(Precision+Recall)=25%

2)
d(x,y)=d(x1,y1)
k=3

Predicted / Target	Positive	Negative
Positive	3	1
Negative	1	3

Precision = 3/4
Recall = 3/4
F1=(2*3/4*3/4)/(3/4+3/4)=75%

When considering the distance between two points to be the distance between their y1 parameters, and evaluating the mode of the 3 closest neighbors, we achieve a F1 measure of 75%, which is three times better than the performance achieved by using Manhattan distance.

3)
$p(z|\mathrm{x}) = (p(\mathrm{x}|z) \times p(z)) \,/\, p(\mathrm{x})$

$p(z)$:
$p(\mathrm{P}) = 5/9$; $p(N) = 4/9$

$p(\mathbf{x}|z)$:
$p(A, 0|\mathrm{P}) = 2/5$; $p(A, 1|\mathrm{P}) = 1/5$; $p(B, 0|P) = 1/5$; $p(B, 1|P) = 1/5$; $p(A, 0|N) = 0$;
$p(A, 1|N) = 1/4$; $p(B, 0|N) = 2/4$; $p(B, 1|N) = 1/4$

Mean and standart deviation values for the PDFs:
Positive class:
μ= (1.1 + 0.8 + 0.5 + 0.9 + 0.8) / 5 = 0.82
σ = sqrt ([(1.1-0.82)^2 + (0.8-0.82)^2 + (0.5-0.82)^2 + (0.9-0.82)^2 + (0.8-0.82)^2] / 5) ≈ 0.1939
N(0.82 , 0.1939)
p(x|P) = (1 / (0.1939 * √(2π))) * e^(-(x-0.82)^2 / (2*0.1939^2))

Negative class:
μ = (1 + 0.9 + 1.2 + 0.9) / 4 = 1
σ = sqrt ([(1-1)^2 + (0.9-1)^2 + (1.2-1)^2 + (0.9-1)^2] / 4) ≈ 0.1225

N(1 , 0.1225)
p(x|N) = (1 / (0.1225* √(2π))) * e^(-(x-1)^2 / (2*0.1225^2))

4)
P(y1,y2,y3|C)=p(y1,y1|C)p(y3|C) because the variable sets {y1,y2} and {y3} are independent
$p(P|\,\mathbf{x}) = p(\mathbf{x}|P)p(P)\ /\ (p(\mathbf{x}|P)p(P) + p(\mathbf{x}|N)p(N))$

(A,1,0.8) :
$p(A, 1, 0.8|P) = p(A, 1|P)p(0.8|P) = 1/5 * 2.0474 \approx\ 0.4095$
$p(A, 1, 0.8|N) = p(A, 1|\mathrm{N})p(0.8|\mathrm{N}) = 1/4 * 0.8586 \approx 0.2147$
$p(P|A, 1, 0.8) = (0.4095 * 5/9)\ /\ ((0.4095 * 5/9 + 0.2147* 4/9) = 0.7045$

(A,1,0.8) is classified as positive

$(B, 1, 1)$:
$p(B, 1, 1|P) = p(B, 1|P)p(1|P) = 1/5 * 1.3377 \approx\ 0.2675$
$p(B, 1, 1|\mathrm{N}) = p(B, 1|\mathrm{N})p(1|\mathrm{N})\ = 1/4 * 3.2573 \approx 0.8143$
$p(P|\mathrm{B}, 1, 1) = (0.2675 * 5/9)\ /\ ((0.2675 * 5/9 + 0.8143 * 4/9) = 0.2911$

$(B, 1, 1)$ is classified as negative

$(B, 0, 0.9)$:
$p(B, 0, 0.9|P) = p(B, 0|P)p(0.9|P) = 1/5 * 1.8904 \approx\ 0.3780$
$p(B, 0, 0.9|\mathrm{N}) = p(B, 0|\mathrm{N})p(0.9|\mathrm{N})\ = 2/4 * 2.3339 \approx 1.1670$
$p(P|\mathrm{B}, 0, 0.9) = (0.3780 * 5/9)\ /\ ((0.3780 * 5/9 + 1.1670 * 4/9) = 0.2882$

$(B, 0, 0.9)$ is classified as negative

5)
P(t\c) =(freq(t) + 1)/Nc + v
P("I"\P)=2/13
P("I"\N)=1/12
P("Iike"\P)=2/13
P("Iike"\N)=1/12
P("to"\P)=1/13
P("to"\N)=1/12
P("run"\P)=2/13
P("run"\N)=2/12
P("I like to run"\P) = 2/13 * 2/13 * 1/13 * 2/13 = 2.801 * 10^-4
P("I like to run"\N) = 1/12 * 1/12 * 1/12 * 2/12 = 9.645 * 10^-5

P("I like to run"\P)*P(P)=1.556*10^-4
P("I like to run"\N)*P(N)=4.287*10^-5
P(P\"I like to run") = 1.556*10^-4/(1.556*10^-4 + 4.287*10^-5) = 0.784

"I like to run" is classified with positive.

Aprendizagem 2023/24

Homework II – Group 024

(ist105887, ist106228)

II. Programming and critical analysis

1)

a)

O modelo Naïve Bayes é mais estável visto que apresenta uma menor variação de accuracy. Isto deve-se, em parte, ao facto do kNN estar mais exposto a pequenas mudanças nos neighbours entre diferentes folds enquanto o Naïve Bayes generaliza melhor com o uso de probabilidades.

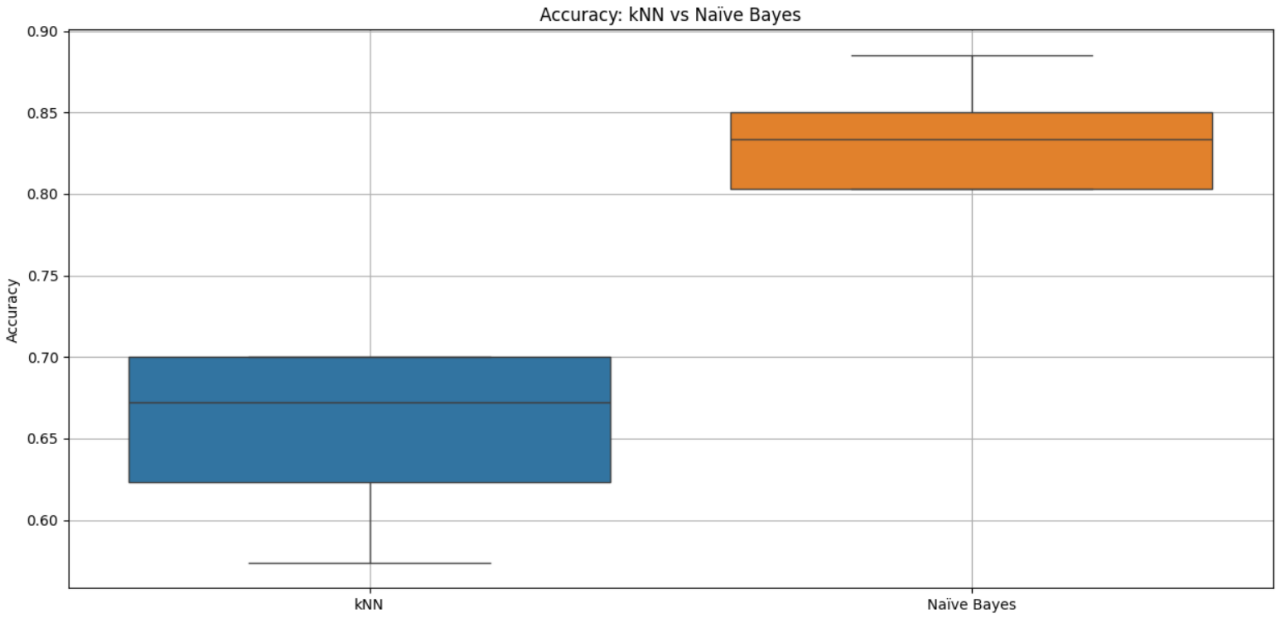

b)

Aplicar o scaler aos modelos tem resultados diferentes. No modelo kNN, escalar os dados permite ter a certeza que variáveis com distâncias maiores não enviesam os dados, atribuindo um valor limitado de 0 a 1 de forma a suavizar a sua influência nos outros dados. No modelo Naïve Bayes, escalar os dados não muda a performance pois o modelo baseia-se em probabilidades que não são afetadas pelo scaling.

c)

Dado o valor do resultado (p-value $\simeq 0.75$), para valores normais de significância (1%, 5% e 10%), aceita-se a hipótese nula (0) e rejeita-se a hipótese 1 que dita que há melhoria na accuracy do kNN comparado com o Naïve Bayes. Logo, não se pode afirmar que há maior accuracy. No entanto, não é correto afirmar que há uma pior ou igual accuracy pois não se pode considerar a hipótese falsa sem mais informação.

Aprendizagem 2023/24

Homework II – Group 024

(ist105887, ist106228)

2)

a)

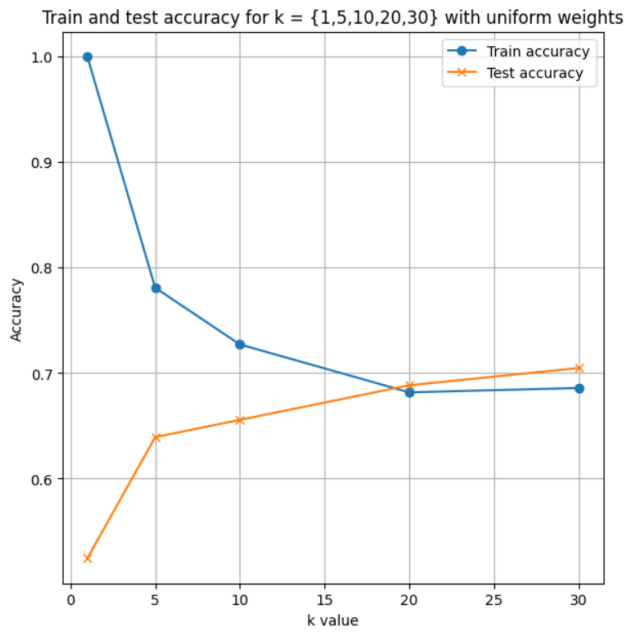

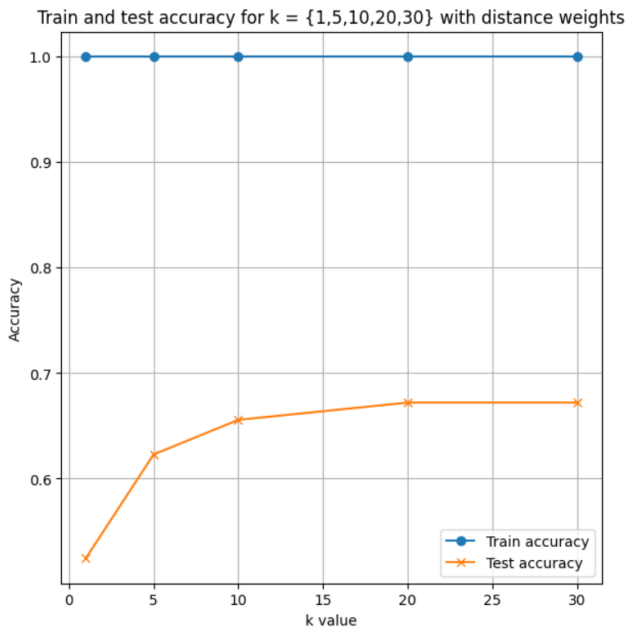

b)

À medida que o valor do k aumenta podemos ver várias tendências em ambos modelos. No modelo com o peso uniforme, quando o k é pequeno, há tendência a overfitting por considerar muito poucos vizinhos, assim a training accuracy é alta (até 100% no caso de k=1, pois apenas se limita a memorizar os dados) mas a test accuracy é baixa devido à dificuldade de classificar novas observações do modelo. Quando o k aumenta, a training accuracy diminui e a test accuracy aumenta pois o modelo considera mais neighbours reduzindo assim a tendência para o overfitting e aumentando a capacidade de generalização. Quando o k é muito elevado, a accuracy não aumenta tanto pois começa a generalizar mais até atingir um ponto perto de perfect fit mas sem ter uma accuracy ótima devido também à generalização que não o permite reconhecer observações mais diferentes. No modelo com o peso por distância, o mesmo acontece para a test accuracy pelas mesmas razões, no entanto, a train accuracy é sempre 100% pois os valores do k são pequenos o suficiente para garantir que são sempre escolhidos no treino os neighbours com a menor distância.

3)

As duas maiores dificuldades do modelo estão relacionadas com as assunções do Naïve Bayes sobre os dados, isto é, que os dados são independentes e que seguem uma distribuição gaussiana. Devido à natureza dos dados, é fácil reparar que algumas variáveis dependem de outras, por exemplo, o nível de colestrol e a pressão sanguínea. Sendo verdade que em alguns casos não faz diferença, pode prejudicar o desempenho do modelo. Além disso, dados categóricos, como o sexo, não seguem distribuições gaussianas causando assim biases ao calcular as probabilidades para o modelo.

END