Aprendizagem 2024
Homework IV – Group 24
(ist105887, ist106228)

Part I: Pen and paper

1. Perform two epochs of the EM clustering algorithm and determine the new parameters.

- **Expectation step:**

$$\mathcal{N}(x|\mu,\Sigma) = \frac{1}{\sqrt{(2\pi)^d|\Sigma|}} \exp\left(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right)$$

$$\gamma_{ki} = p(c_k \mid x_i) = \frac{p(x_i \mid c_k)p(c_k)}{p(x_i)} = \frac{\mathcal{N}(x_i \mid \mathbf{u}_k, \Sigma_k)\cdot\pi_k}{\sum_k \pi_k \mathcal{N}(x_i \mid \mathbf{u}_k, \Sigma_k)}$$

First, calculate the Mahalanobis distance term and the determinant of the covariance matrices:

$$(x_1-\mu_1)^T\Sigma_1^{-1}(x_1-\mu_1) = \left(\begin{bmatrix}1\\0\end{bmatrix} - \begin{bmatrix}2\\-1\end{bmatrix}\right)^T \begin{bmatrix}4 & 1\\1 & 4\end{bmatrix}^{-1} \left(\begin{bmatrix}1\\0\end{bmatrix} - \begin{bmatrix}2\\-1\end{bmatrix}\right) = 0.667$$

$$(x_2-\mu_1)^T\Sigma_1^{-1}(x_2-\mu_1) = \left(\begin{bmatrix}0\\2\end{bmatrix} - \begin{bmatrix}2\\-1\end{bmatrix}\right)^T \begin{bmatrix}4 & 1\\1 & 4\end{bmatrix}^{-1} \left(\begin{bmatrix}0\\2\end{bmatrix} - \begin{bmatrix}2\\-1\end{bmatrix}\right) = 4.267$$

$$(x_3-\mu_1)^T\Sigma_1^{-1}(x_3-\mu_1) = \left(\begin{bmatrix}3\\-1\end{bmatrix} - \begin{bmatrix}2\\-1\end{bmatrix}\right)^T \begin{bmatrix}4 & 1\\1 & 4\end{bmatrix}^{-1} \left(\begin{bmatrix}3\\-1\end{bmatrix} - \begin{bmatrix}2\\-1\end{bmatrix}\right) = 0.267$$

$$(x_1-\mu_2)^T\Sigma_2^{-1}(x_1-\mu_2) = \left(\begin{bmatrix}1\\0\end{bmatrix} - \begin{bmatrix}1\\1\end{bmatrix}\right)^T \begin{bmatrix}2 & 0\\0 & 2\end{bmatrix}^{-1} \left(\begin{bmatrix}1\\0\end{bmatrix} - \begin{bmatrix}1\\1\end{bmatrix}\right) = 0.5$$

$$(x_2-\mu_2)^T\Sigma_2^{-1}(x_2-\mu_2) = \left(\begin{bmatrix}0\\2\end{bmatrix} - \begin{bmatrix}1\\1\end{bmatrix}\right)^T \begin{bmatrix}2 & 0\\0 & 2\end{bmatrix}^{-1} \left(\begin{bmatrix}0\\2\end{bmatrix} - \begin{bmatrix}1\\1\end{bmatrix}\right) = 1$$

$$(x_3-\mu_2)^T\Sigma_2^{-1}(x_3-\mu_2) = \left(\begin{bmatrix}3\\-1\end{bmatrix} - \begin{bmatrix}1\\1\end{bmatrix}\right)^T \begin{bmatrix}2 & 0\\0 & 2\end{bmatrix}^{-1} \left(\begin{bmatrix}3\\-1\end{bmatrix} - \begin{bmatrix}1\\1\end{bmatrix}\right) = 4$$

$$|\Sigma_1| = 16 - 1 = 15$$
$$|\Sigma_2| = 4 - 0 = 4$$

Then, apply the Gaussian PDF formula:

$$\mathcal{N}(x_1|\mu_1,\Sigma_1) = \frac{1}{2\pi\sqrt{15}} \cdot e^{-\frac{1}{2}\cdot 0.667} = 0.029$$

$$\mathcal{N}(x_2|\mu_1,\Sigma_1) = \frac{1}{2\pi\sqrt{15}} \cdot e^{-\frac{1}{2}\cdot 4.267} = 0.005$$

$$\mathcal{N}(x_3|\mu_1, \Sigma_1) = \frac{1}{2\pi\sqrt{15}} \cdot e^{-\frac{1}{2}\cdot 0.267} = 0.036$$

$$\mathcal{N}(x_1|\mu_2, \Sigma_2) = \frac{1}{2\pi\sqrt{4}} \cdot e^{-\frac{1}{2}\cdot 0.5} = 0.062$$

$$\mathcal{N}(x_2|\mu_2, \Sigma_2) = \frac{1}{2\pi\sqrt{4}} \cdot e^{-\frac{1}{2}\cdot 1} = 0.048$$

$$\mathcal{N}(x_3|\mu_2, \Sigma_2) = \frac{1}{2\pi\sqrt{4}} \cdot e^{-\frac{1}{2}\cdot 4} = 0.011$$

Calculate the responsibility:

$$\gamma_{1,1} = \frac{0.029 * 0.5}{0.029x0.5 + 0.062x0.5} = 0.319$$

$$\gamma_{1,2} = \frac{0.005 * 0.5}{0.005x0.5 + 0.048x0.5} = 0.094$$

$$\gamma_{1,3} = \frac{0.036 * 0.5}{0.036x0.5 + 0.011x0.5} = 0.766$$

$$\gamma_{2,1} = 1 - 0.319 = 0.681$$

$$\gamma_{2,2} = 1 - 0.094 = 0.906$$

$$\gamma_{2,3} = 1 - 0.766 = 0.234$$

- **Maximization step:**

$$N_k = \sum_{i=1}^{n} \gamma_{ki}$$

$$\mathbf{u}_k = \frac{1}{N_k} \sum_{i=1}^{n} \gamma_{ki} \cdot \mathbf{x}_i$$

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^{n} \gamma_{ki} \cdot (\mathbf{x}_i - \mathbf{u}_k) \cdot (\mathbf{x}_i - \mathbf{u}_k)^T$$

$$\pi_k = p(c_k) = \frac{N_k}{N}$$

$$\mathcal{N}_1 = 0.319 + 0.094 + 0.766 = 1.179$$
$$\mathcal{N}_2 = 0.681 + 0.906 + 0.234 = 1.821$$

$$\pi_1 = \frac{1.179}{3} = 0.393$$

$$\pi_2 = \frac{1.821}{3} = 0.607$$

$$\mathbf{u}_1 = \begin{bmatrix} 2.220 \\ -0.490 \end{bmatrix}$$

$$\mathbf{u}_2 = \begin{bmatrix} 1.383 \\ 1.578 \end{bmatrix}$$

$$\Sigma_1 = \begin{bmatrix} 1.191 & -0.862 \\ -0.862 & 0.729 \end{bmatrix}$$

$$\Sigma_2 = \begin{bmatrix} 1.343 & -0.600 \\ -0.600 & 1.874 \end{bmatrix}$$

- **Expectation step:**

$$|\Sigma_1| = 1.191 \times 0.729 - (-0.862)^2 = 0.868 - 0.743 = 0.125$$

$$|\Sigma_2| = 1.343 \times 1.874 - (-0.600)^2 = 2.516 - 0.360 = 2.156$$

$$\Sigma_1^{-1} = \frac{1}{|\Sigma_1|} \begin{bmatrix} 0.729 & 0.862 \\ 0.862 & 1.191 \end{bmatrix} = \frac{1}{0.125} \begin{bmatrix} 0.729 & 0.862 \\ 0.862 & 1.191 \end{bmatrix} = \begin{bmatrix} 5.832 & 6.896 \\ 6.896 & 9.528 \end{bmatrix}$$

$$\Sigma_2^{-1} = \frac{1}{|\Sigma_2|} \begin{bmatrix} 1.874 & 0.600 \\ 0.600 & 1.343 \end{bmatrix} = \frac{1}{2.156} \begin{bmatrix} 1.874 & 0.600 \\ 0.600 & 1.343 \end{bmatrix} = \begin{bmatrix} 0.869 & 0.278 \\ 0.278 & 0.623 \end{bmatrix}$$

$$(x_1 - \mu_1)^T \Sigma_1^{-1} (x_1 - \mu_1) = \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 2.220 \\ -0.490 \end{bmatrix} \right)^T \begin{bmatrix} 5.832 & 6.896 \\ 6.896 & 9.528 \end{bmatrix} \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 2.220 \\ -0.490 \end{bmatrix} \right) = 2.719$$

$$(x_1 - \mu_2)^T \Sigma_2^{-1} (x_1 - \mu_2) = \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 1.383 \\ 1.578 \end{bmatrix} \right)^T \begin{bmatrix} 0.869 & 0.278 \\ 0.278 & 0.623 \end{bmatrix} \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 1.383 \\ 1.578 \end{bmatrix} \right) = 2.014$$

$$(x_2 - \mu_1)^T \Sigma_1^{-1} (x_2 - \mu_1) = \left(\begin{bmatrix} 0 \\ 2 \end{bmatrix} - \begin{bmatrix} 2.220 \\ -0.490 \end{bmatrix} \right)^T \begin{bmatrix} 5.832 & 6.896 \\ 6.896 & 9.528 \end{bmatrix} \left(\begin{bmatrix} 0 \\ 2 \end{bmatrix} - \begin{bmatrix} 2.220 \\ -0.490 \end{bmatrix} \right) = 11.560$$

$$(x_2 - \mu_2)^T \Sigma_2^{-1} (x_2 - \mu_2) = \left(\begin{bmatrix} 0 \\ 2 \end{bmatrix} - \begin{bmatrix} 1.383 \\ 1.578 \end{bmatrix} \right)^T \begin{bmatrix} 0.869 & 0.278 \\ 0.278 & 0.623 \end{bmatrix} \left(\begin{bmatrix} 0 \\ 2 \end{bmatrix} - \begin{bmatrix} 1.383 \\ 1.578 \end{bmatrix} \right) = 1.448$$

$$(x_3 - \mu_1)^T \Sigma_1^{-1} (x_3 - \mu_1) = \left(\begin{bmatrix} 3 \\ -1 \end{bmatrix} - \begin{bmatrix} 2.220 \\ -0.490 \end{bmatrix} \right)^T \begin{bmatrix} 5.832 & 6.896 \\ 6.896 & 9.528 \end{bmatrix} \left(\begin{bmatrix} 3 \\ -1 \end{bmatrix} - \begin{bmatrix} 2.220 \\ -0.490 \end{bmatrix} \right) = 0.539$$

$$(x_3 - \mu_2)^T \Sigma_2^{-1} (x_3 - \mu_2) = \left(\begin{bmatrix} 3 \\ -1 \end{bmatrix} - \begin{bmatrix} 1.383 \\ 1.578 \end{bmatrix} \right)^T \begin{bmatrix} 0.869 & 0.278 \\ 0.278 & 0.623 \end{bmatrix} \left(\begin{bmatrix} 3 \\ -1 \end{bmatrix} - \begin{bmatrix} 1.383 \\ 1.578 \end{bmatrix} \right) = 4.091$$

Then, apply the Gaussian PDF formula:

$$\mathcal{N}(x_1|\mu_1, \Sigma_1) = \frac{1}{2\pi\sqrt{0.125}} \cdot e^{-\frac{1}{2}\cdot 2.719} = 0.116$$

$$\mathcal{N}(x_1|\mu_2, \Sigma_2) = \frac{1}{2\pi\sqrt{2.156}} \cdot e^{-\frac{1}{2}\cdot 2.014} = 0.039$$

$$\mathcal{N}(x_2|\mu_1, \Sigma_1) = \frac{1}{2\pi\sqrt{0.125}} \cdot e^{-\frac{1}{2}\cdot 11.560} = 0.00135$$

$$\mathcal{N}(x_2|\mu_2, \Sigma_2) = \frac{1}{2\pi\sqrt{2.156}} \cdot e^{-\frac{1}{2}\cdot 1.448} = 0.052$$

$$\mathcal{N}(x_3|\mu_1, \Sigma_1) = \frac{1}{2\pi\sqrt{0.125}} \cdot e^{-\frac{1}{2}\cdot 0.539} = 0.344$$

$$\mathcal{N}(x_3|\mu_2, \Sigma_2) = \frac{1}{2\pi\sqrt{2.156}} \cdot e^{-\frac{1}{2}\cdot 4.091} = 0.014$$

Calculate the responsibilities:

$$\gamma_{11} = \frac{0.393 \cdot 0.116}{0.393 \cdot 0.116 + 0.607 \cdot 0.039} = \frac{0.045588}{0.069261} \approx 0.658$$

$$\gamma_{12} = \frac{0.393 \cdot 0.00135}{0.393 \cdot 0.00135 + 0.607 \cdot 0.052} = \frac{0.000531}{0.032095} \approx 0.017$$

$$\gamma_{13} = \frac{0.393 \cdot 0.344}{0.393 \cdot 0.344 + 0.607 \cdot 0.014} = \frac{0.135192}{0.143690} \approx 0.941$$

$$\gamma_{21} = \frac{0.607 \cdot 0.039}{0.393 \cdot 0.116 + 0.607 \cdot 0.039} = \frac{0.023673}{0.069261} \approx 0.342$$

$$\gamma_{22} = \frac{0.607 \cdot 0.052}{0.393 \cdot 0.00135 + 0.607 \cdot 0.052} = \frac{0.031564}{0.032095} \approx 0.983$$

$$\gamma_{23} = \frac{0.607 \cdot 0.014}{0.393 \cdot 0.344 + 0.607 \cdot 0.014} = \frac{0.008498}{0.143690} \approx 0.059$$

- **Maximization step:**

$$\mathcal{N}_1 = 0.658 + 0.017 + 0.941 = 1.616$$

$$\mathcal{N}_2 = 0.342 + 0.983 + 0.059 = 1.384$$

$$\pi_1 = \frac{1.616}{3} = 0.539$$

$$\pi_2 = \frac{1.384}{3} = 0.461$$

$$\mathbf{u}_1 = \begin{bmatrix} 2.154 \\ -0.561 \end{bmatrix}$$

$$\mathbf{u}_2 = \begin{bmatrix} 0.375 \\ 1.378 \end{bmatrix}$$

$$\Sigma_1 = \begin{bmatrix} 1.008 & -0.538 \\ -0.538 & 0.309 \end{bmatrix}$$

$$\Sigma_2 = \begin{bmatrix} 0.490 & -0.645 \\ -0.645 & 0.985 \end{bmatrix}$$

2. Using the final parameters computed in previous question:

   (a) Perform a hard assignment of observations to clusters under a MAP assumption

$$\hat{c}_i = \arg\max_j \gamma_{ji}$$

$$\text{clusters} = \{c_1 = \{\mathbf{x}_1, \mathbf{x}_3\},\ c_2 = \{\mathbf{x}_2\}\}$$

   (b) compute the silhouette of the larger cluster (the one that has more observations assigned to it) using the Euclidean distance.

$$s(\mathbf{x}_1) = \frac{b(\mathbf{x}_1)}{a(\mathbf{x}_1} - 1 = \frac{\|\mathbf{x}_1 - \mathbf{x}_2\|_2}{\|\mathbf{x}_1 - \mathbf{x}_3\|_2} - 1 = \frac{\sqrt{5}}{\sqrt{5}} - 1 = 0$$

$$s(\mathbf{x}_3) = 1 - \frac{a(\mathbf{x}_3)}{b(\mathbf{x}_3)} = 1 - \frac{\|\mathbf{x}_3 - \mathbf{x}_1\|_2}{\|\mathbf{x}_3 - \mathbf{x}_2\|_2} = 1 - \frac{\sqrt{5}}{\sqrt{18}} = 0.473$$

$$s(c_1) = \frac{s(\mathbf{x}_2) + s(\mathbf{x}_3)}{2} = 0.2365$$

Part II: Programming

1. (a) .

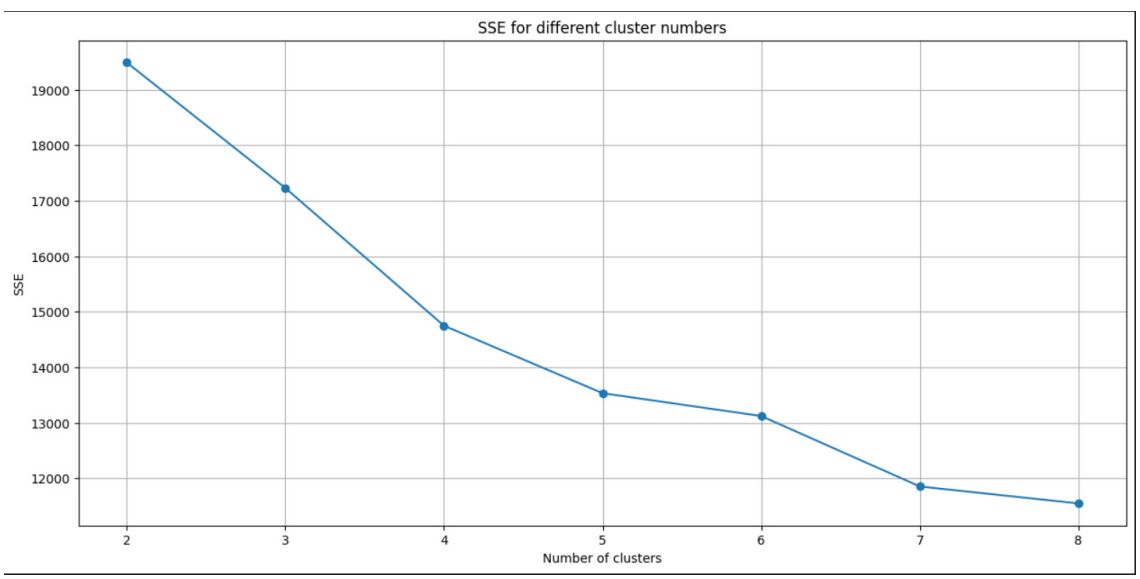

(b) Aumentando o número de clusters, diminui-se a inertia (SSE) e aumenta-se a proximidade dos pontos do cluster ao centróide, aumentando a performance do modelo. No entanto, aumentar demasiado o número de clusters pode causar overfitting, logo, é necessário encontrar o ponto de balanço entre a inertia e o número de clusters. Analisando o gráfico, podemos observar que o ponto a partir de qual a inertia começa a descer mais lentamente é nos 4 clusters. Sendo assim, aumentar o número de clusters não vai trazer uma grande melhoria em performance mas pode levar a overfitting. Logo, é seguro dizer que o número ideal de clusters é 4.

(c) Ambas approaches requerem conversões de variáveis do CSV original. A approach k-modes requeria converter as variáveis ”age” e ”balance” parecendo assim a melhor approach pois requer apenas 2 conversões, ao contrário de k-means que necessitaria de 6 conversões de variáveis. No entanto, num dataset com as variáveis binárias mapeadas a valores numéricos, a approach k-means seria a melhor por ter de converter apenas 3 variáveis.

2. (a) Explained variance = [0.11825412 0.11127853]

(b) Os clusters não são claramente separáveis. Embora os pontos estejam maioritariamente agrupados por cluster, os grupos tocam-se nos seus limites, indicando uma sobreposição parcial. Isto implica que as componentes escolhidas para o PCA não captam totalmente as distinções entre todas as variáveis ou que existem semelhanças entre variáveis.

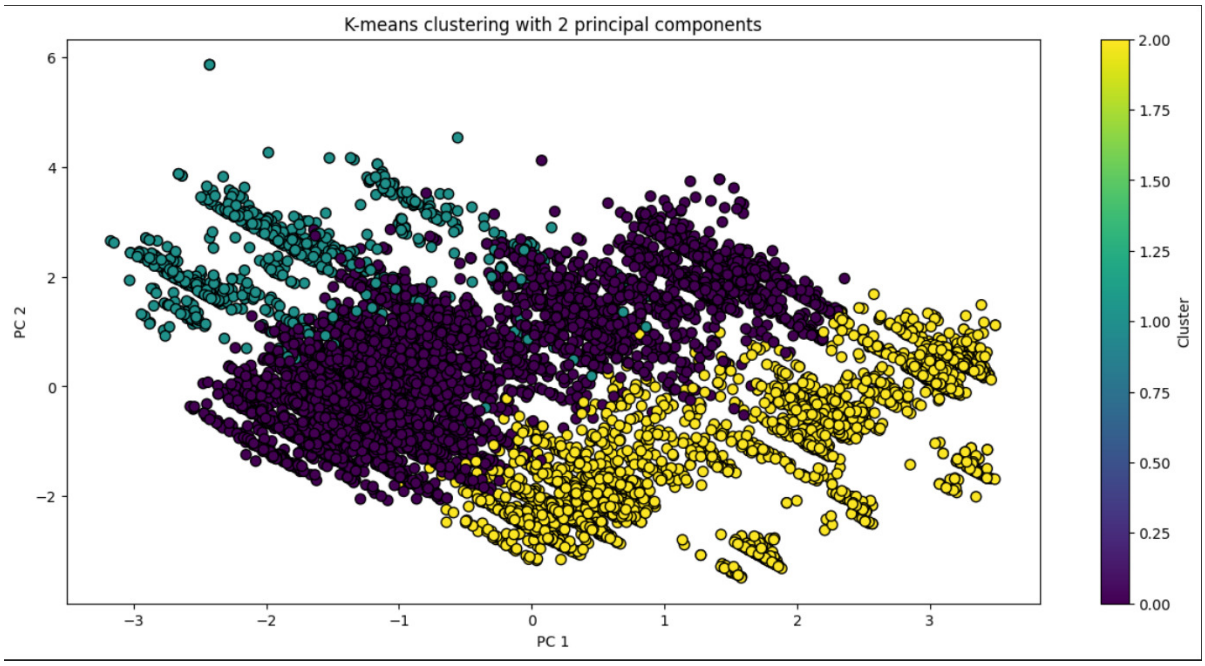

(c) A análise dos clusters revela padrões distintos tanto nos tipos de emprego como na educação dos clientes. Ao nível de emprego, o cluster 0 tem uma maior concentração de clientes em trabalhos mais práticos e de gestão, indicando um grupo com empregos mais estáveis mas, geralmente, com menor rendimento. O cluster 1 apenas contém clientes reformados, indicando uma média de idade bastante avançada e uma maior segurança de rendimento. O cluster 2 apresenta uma distribuição parecida à do cluster 0, mas inclui um maior número de clientes que são estudantes ou estão em cargos menos práticos, indicando, assim, um menor rendimento médio, uma maior instabilidade financeira e uma idade média mais reduzida. Ao nível da educação, o cluster 0 apresenta uma maioria de clientes com o ensino secundário ou
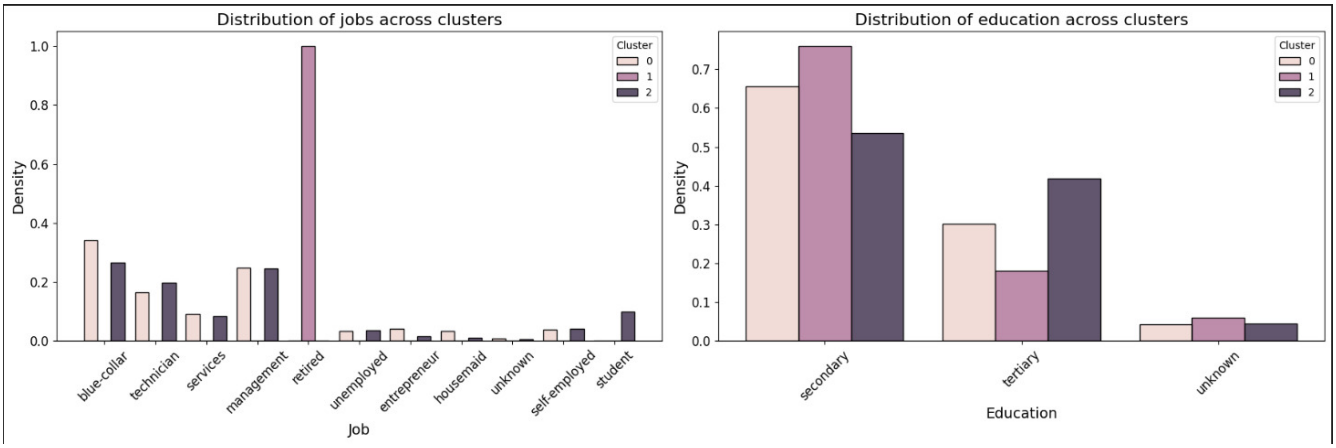
inferior, verificado pela distribuição de empregos que corresponde a maioritáriamente blue-collar jobs. O cluster 1 apresenta uma maior percentagem de clientes com ensino secundário mas menos com educação superior, sugerindo clientes com maior idade, demografia esta com menor difusão de ensino superior. O cluster 2 um número significativo de clientes com ensino superior, concordante com o maior número de estudantes. Resumindo, o cluster 0 é caracterizado por uma maior estabilidade no emprego e educação, o cluster 1 é marcado por uma totalidade de clientes reformados e o Cluster 2 representa uma tendência para clientes mais jovens.